

第 9 章 序列标注 – 隐马尔科夫模型

1/2

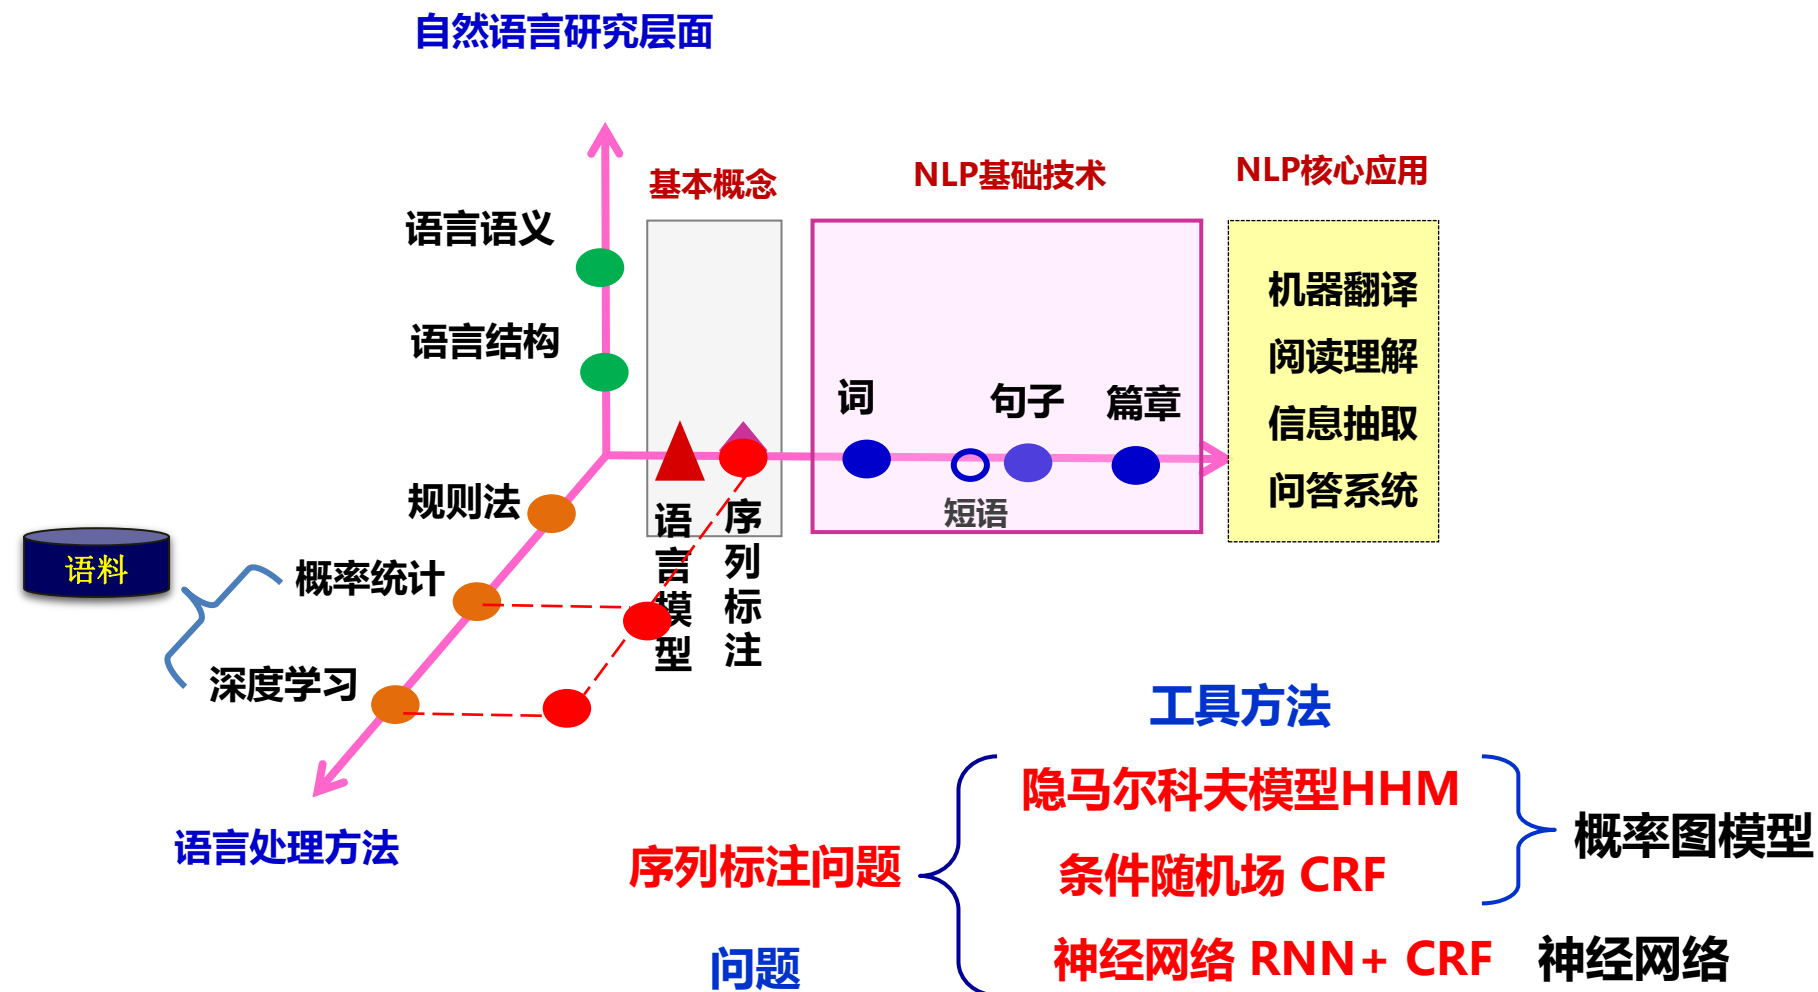
中科院信息工程研究所第二研究室

胡玥

huyue@iie.ac.cn

自然语言处理课程内容及安排

◇ 课程内容：



内 容 提 要

9.1 序列标注问题

9.2 隐马尔科夫模型HMM

9.3 条件随机场 CRF

9.4 神经网络 RNN+ CRF

9.1 序列标注问题

问题引入

在自然语言处理任务中，有许多的任务可以转化为“将输入的语言序列转化为标注序列”来解决问题。如，命名实体识别、信息抽取、词性标注.....

- 命名实体识别（人名识别）

目标：将给定的输入序列中的人名识别出来

如：输入序列： 新任总裁罗建国宣布了对部门经理邓奇的任免通知

↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓


输出序列： 0 0 0 0 B I E 0 0 0 0 0 0 0 0 B E 0 0 0 0 0

{ B I E O } 或 { B I O }

B - 词首
I - 词中
E - 词尾
O - 单个词

9.1 序列标注问题

序列标注问题：



标注问题是分类问题的推广，是复杂结构预测的简单形式（监督学习）

许多自然语言处理问题 均可转化为序列标注问题

9.1 序列标注问题

- 命名实体识别（组织机构名识别）

目标：将给定的输入序列中的组织机构名识别出来

输入序列：新任总裁罗建国宣布了对远大公司经理国庆的任免通知

标注序列：0 0 0 0 0 0 0 0 0 0 B I I E 0 0 0 0 0 0 0 0

- 信息抽取

目标：将给定的输入序列中的军事术语抽取出来

输入：鹰式战斗机是一款极为优秀的多用途战斗机

输出：B I I I E 0 0 0 0 0 0 0 0 B I I I I E

9.1 序列标注问题

- 词性序列标注 (POS)

目标：将给定的输入序列中词的词性标出来

如： 输入： Flies like a flower

输出： N V ART N

词性标注结果： Flies/**N** like /**V** a/**ART** flower/**N**

$f: X \rightarrow Y$

Y的符号集 { 单词的词性, 如 N 、 V 等 }

- 分词、短语识别、依存分析、语义角色标注.....

内 容 提 要

9.1 序列标注问题

9.2 隐马尔科夫模型HMM

9.2.1 马尔科夫模型

9.2.2 隐马尔科夫模型（结构）

9.2.3 隐马尔科夫模型学习


9.2.4 隐马模型应用

9.3 条件随机场 CRF

9.4 神经网络 RNN+ CRF

9.2.1 马尔科夫模型

马尔可夫 (Andrei Andreyevich Markov, 1856.6.14 ~ 1922.7.20)




前苏联数学家。切比雪夫(1821年5月16日 ~ 1894年12月8日)的学生。在概率论、数论、函数逼近论和微分方程等方面卓有成就。他提出了用数学分析方法研究自然过程的一般图式—马尔可夫链，并**开创了随机过程(马尔可夫过程)**的研究。

9.2.1 马尔科夫模型

马尔可夫链

一个系统有 N 个状态 S_1, S_2, \dots, S_n ,


抽象系统





天气： $N=3$



骰子： $N=6$



随着时间（空间）推移，系统从某一状态转移到另一状态，**注意状态序列和状态集的区别**



如果系统在 t 时间的状态 q_t 只与其在时间 $t-1$ 的状态相关，则系统构成离散的一阶**马尔可夫链(马尔可夫过程)**


马尔可夫假设

9.2.1 马尔科夫模型

马尔可夫模型：

$$p(S_0, S_1, \dots, S_T) = \prod_{t=1}^T p(S_t | S_{t-1}) p(S_0)$$

马尔可夫链



独立于时间 t 的随机过程：

$$P(q_t = S_j | q_{t-1} = S_i) = a_{i,j}, 1 \leq i, j \leq N$$

其中：状态转移概率 a_{ij} 必须满足 $a_{ij} \geq 0$,

$$\text{且} \quad \sum_{j=1}^N a_{i,j} = 1$$

模型输入：状态序列

模型输出：状态序列的概率值

模型参数： $P(q_t | q_{t-1})$

9.2.1 马尔科夫模型


■ 马尔可夫模型组成

三元组 $M = (S, \pi, A)$


参数	含义
S	模型中状态的有限集合
A	与时间无关的状态转移概率矩阵
π	初始状态空间的概率分布

■ 马尔可夫模型作用:

定量描述随机事件的变化过程



$S = \{s_1, s_2, s_3, \dots, s_n\}$



$A = [a_{ij}] =$

	s_1	s_2	s_3	\dots	s_n
s_1	a_{11}	a_{12}	a_{13}	\dots	a_{1n}
s_2	a_{21}	a_{22}	a_{23}	\dots	a_{2n}
s_3	\vdots				
\vdots					
s_n	a_{n1}	a_{n2}	a_{n3}	\dots	a_{nr}

其中：状态转移概率 a_{ij}

$$P(q_t = S_j | q_{t-1} = S_i) = a_{i,j}, 1 \leq i, j \leq N$$

满足 $a_{ij} \geq 0$, 且 $\sum_{j=1}^N a_{i,j} = 1$

π 初始状态向量


9.2.1 马尔科夫模型

马尔可夫模型作用

三元组 $M = (S, \pi, A)$

参数	含义
S	模型中状态的有限集合
A	与时间无关的状态转移概率矩阵
π	初始状态空间的概率分布

例1：掷骰子



$S = \{1, 2, 3, 4, 5, 6\}$

A


	1	2	3	4	5	6
1	1/6	1/6	1/6	1/6	1/6	1/6
2	1/6	1/6	1/6	1/6	1/6	1/6
3	1/6	1/6	1/6	1/6	1/6	1/6
4	1/6	1/6	1/6	1/6	1/6	1/6
5	1/6	1/6	1/6	1/6	1/6	1/6
6	1/6	1/6	1/6	1/6	1/6	1/6

其中：状态转移概率 a_{ij}

$$P(q_t = S_j | q_{t-1} = S_i) = a_{i,j}, 1 \leq i, j \leq N$$

满足 $a_{ij} \geq 0$ ，且 $\sum_{j=1}^N a_{i,j} = 1$

马尔科夫模型定量描述随机事件：



$\pi = (1, 0, 0, 0, 0, 0)$

9.2.1 马尔科夫模型

马尔可夫模型作用


三元组 $M = (S, \pi, A)$

参数	含义
S	模型中状态的有限集合
A	与时间无关的状态转移概率矩阵
π	初始状态空间的概率分布

定量描述随机事件：天气变化



例2：预测天气变化



$S = \{ \text{晴 云 雨} \}$

A

	晴天	阴天	下雨
晴天	0.50	0.25	0.25
阴天	0.375	0.25	0.375
下雨	0.25	0.125	0.625

其中：状态转移概率 a_{ij}

$$P(q_t = S_j \mid q_{t-1} = S_i) = a_{i,j}, 1 \leq i, j \leq N$$

$$\text{满足 } a_{ij} \geq 0, \text{ 且 } \sum_{j=1}^N a_{i,j} = 1$$


$\pi = (1, 0, 0)$

9.2.1 马尔科夫模型

例3： 假定一段时间内的气象可由一3状态马尔可夫模型 M 描述：

S_1 ：雨， S_2 ：多云， S_3 ：晴，转移概率矩阵为：

		S_1	S_2	S_3
$A = [a_{ij}] =$	S_1	0.4	0.3	0.3
	S_2	0.2	0.6	0.2
	S_3	0.1	0.1	0.8



如果第一天为晴天，根据这一模型，求在今后七天中天气为 $S =$ “晴晴雨雨晴云晴” 的概率

即，求



的概率

9.2.1 马尔科夫模型

解： 马尔可夫模型状态序列概率：

$$p(S_0, S_1, \dots, S_T) = \prod_{t=1}^T p(S_t | S_{t-1}) p(S_0)$$

S = 晴 晴 雨 雨 晴 云 晴

$$\begin{aligned} P(O | M) &= P(S_3, S_3, S_3, S_1, S_1, S_3, S_2, S_3 | M) \\ &= P(S_3) \cdot P(S_3 | S_3) \cdot P(S_3 | S_3) \cdot P(S_1 | S_3) \cdot P(S_1 | S_1) \cdot \\ &\quad P(S_3 | S_1) \cdot P(S_2 | S_3) \cdot P(S_3 | S_2) \\ &= 1 \cdot a_{33} \cdot a_{33} \cdot a_{31} \cdot a_{11} \cdot a_{13} \cdot a_{32} \cdot a_{23} \\ &= (0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2) \\ &= 1.536 \times 10^{-4} \end{aligned}$$

	雨	云	晴
雨	0.4	0.3	0.3
云	0.2	0.6	0.2
晴	0.1	0.1	0.8

A = [a_{ij}]=

内 容 提 要

9.1 序列标注问题

9.2 隐马尔科夫模型HMM

9.2.1 马尔科夫模型

9.2.2 隐马尔科夫模型（结构）

9.2.3 隐马尔科夫模型学习

9.2.4 隐马模型应用

9.3 条件随机场 CRF

9.4 神经网络 RNN+ CRF

9.2.2 隐马尔科夫模型（结构）

隐马尔可夫模型（Hidden Markov Model, HMM）

--- 创建于20世纪70年代 ---


描写：该模型是一个双重随机过程，我们不知道具体的状态序列，只知道状态转移的概率，即模型的状态转换过程是不可观察的（隐蔽的），而可观察事件的随机过程是隐蔽状态转换过程的随机函数。

通过可见的事物的变化揭示深藏其后的内在的本质规律

9.2.2 隐马尔科夫模型（结构）

马尔可夫模型：

S:




A:

	雨	云	晴
雨	0.4	0.3	0.3
云	0.2	0.6	0.2
晴	0.1	0.1	0.8

π : 晴 云 雨
(1, 0, 0)


天气变化



9.2.2 隐马尔科夫模型（结构）

马尔可夫模型： \longrightarrow 隐马尔可夫模型 HMM

S:

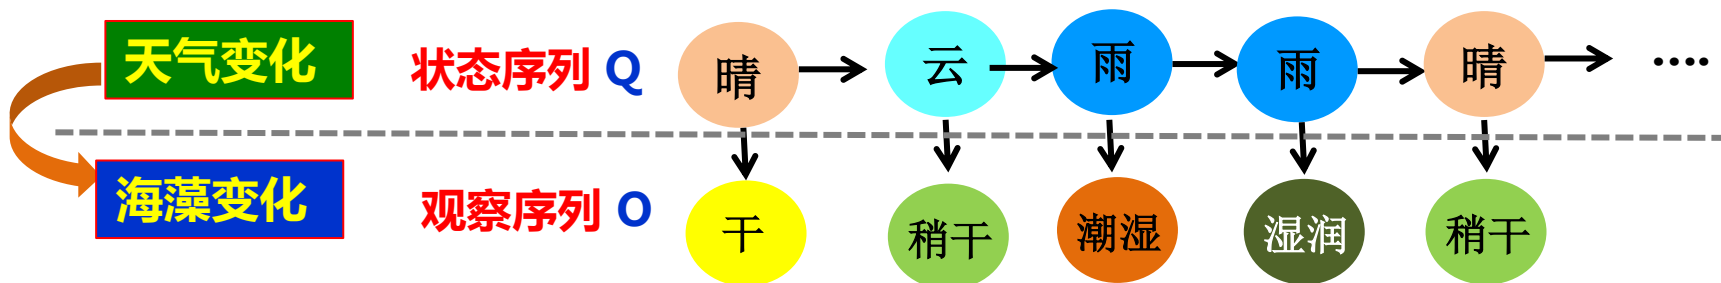


A:


	雨	云	晴
雨	0.4	0.3	0.3
云	0.2	0.6	0.2
晴	0.1	0.1	0.8

$A = [a_{ij}] =$

π : 晴 云 雨
(1, 0, 0)



O:



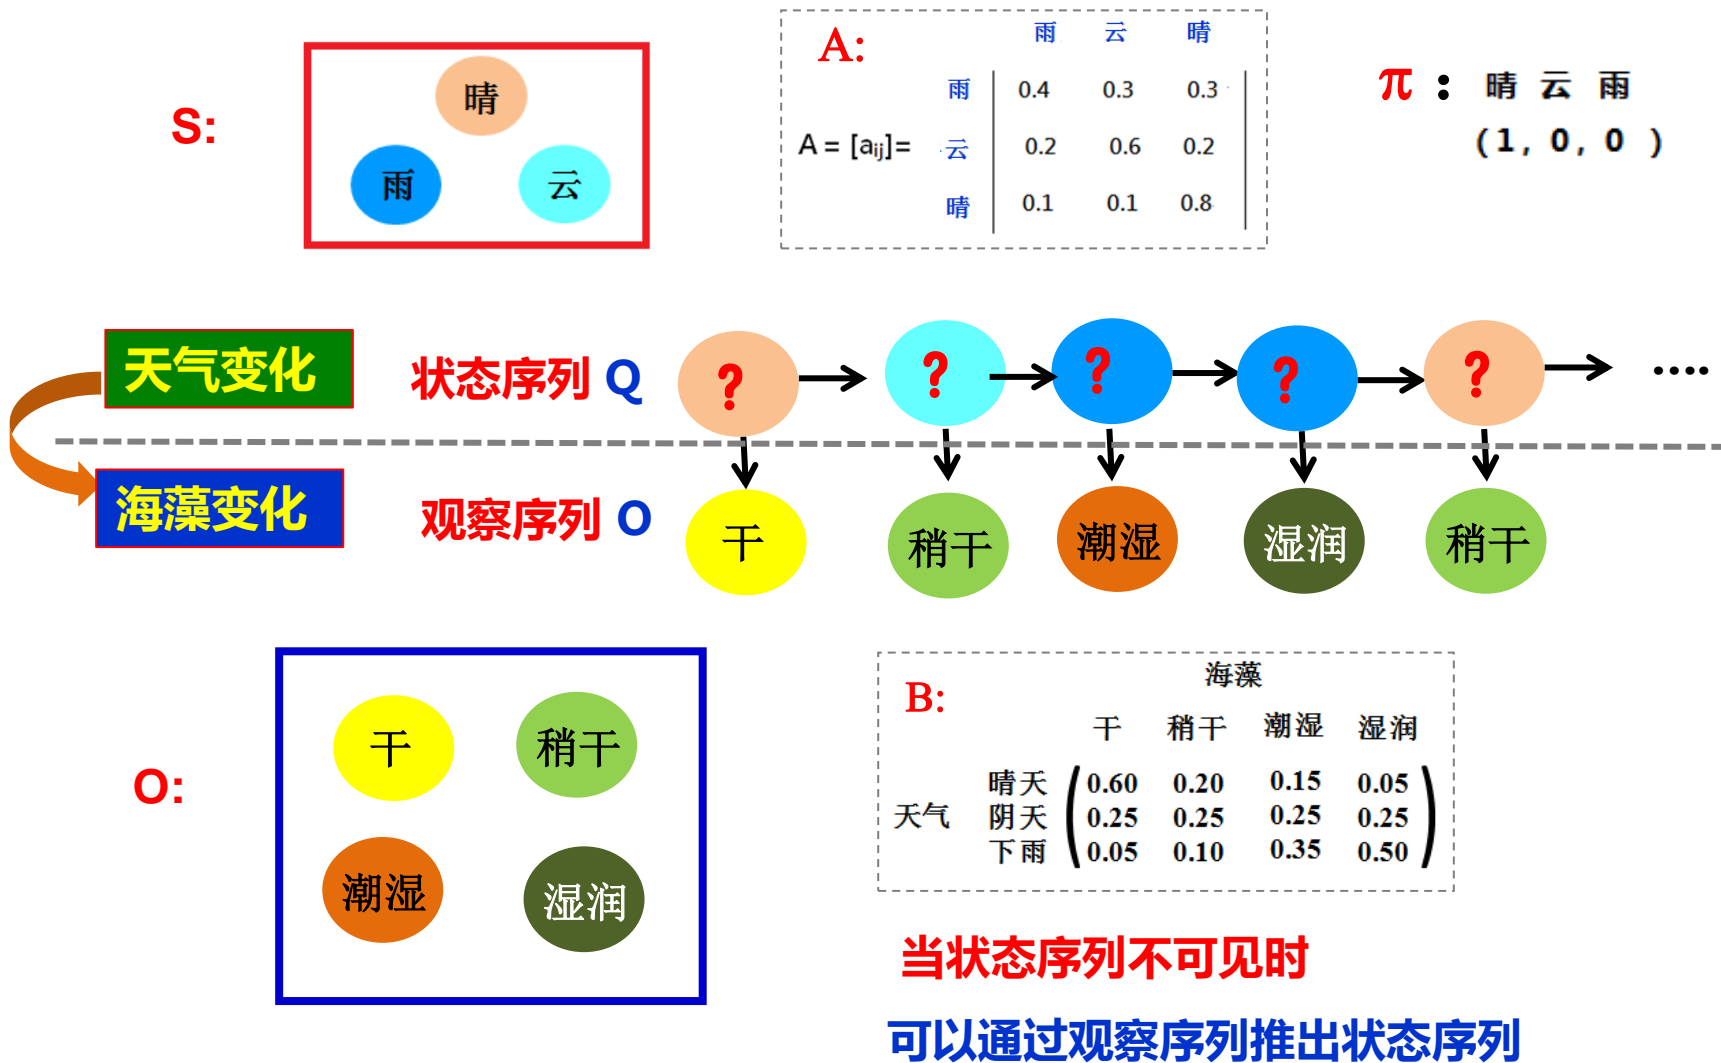
B:

		海藻			
		干	稍干	潮湿	湿润
天气	晴天	0.60	0.20	0.15	0.05
	阴天	0.25	0.25	0.25	0.25
	下雨	0.05	0.10	0.35	0.50

观察序列变化由状态序列变化引起
(两者相关联)

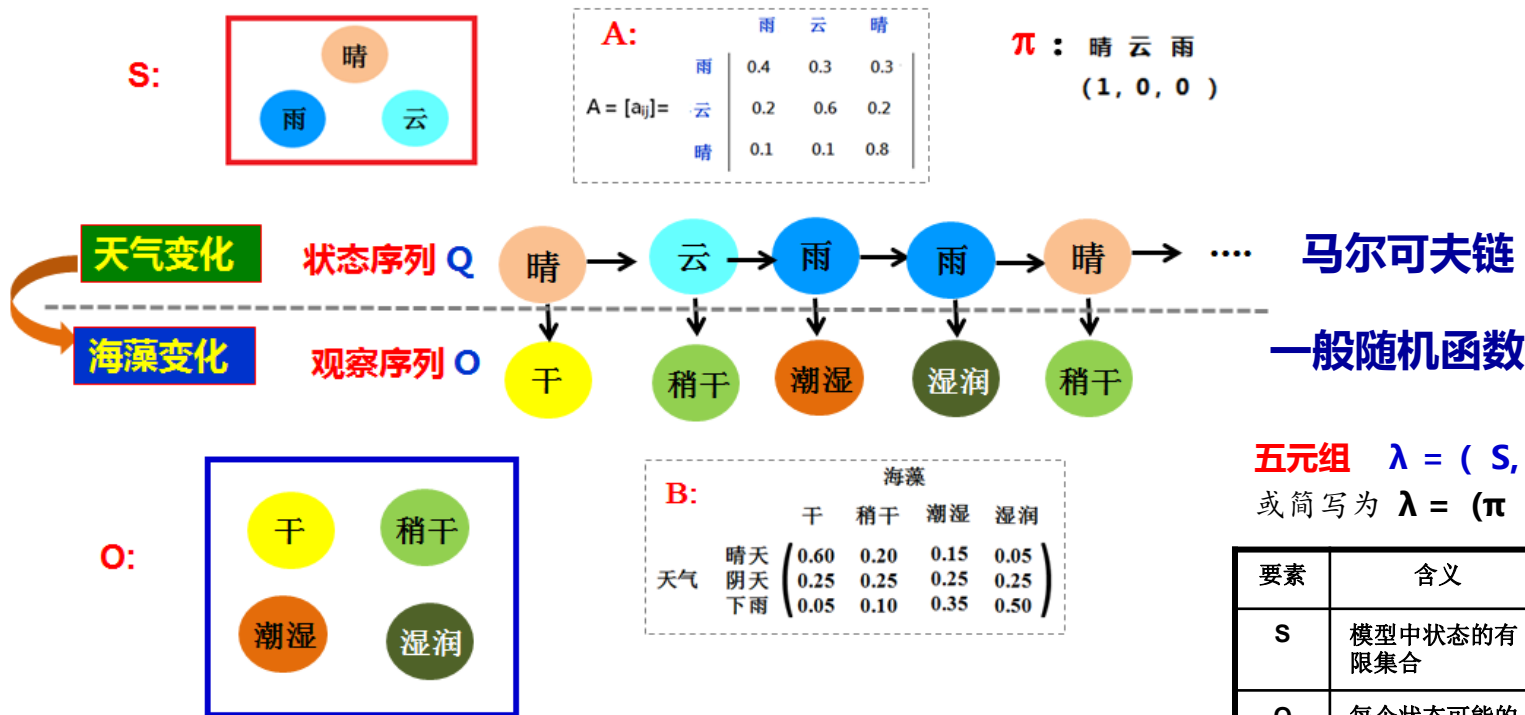
9.2.2 隐马尔科夫模型（结构）

隐马尔可夫模型 HMM作用



9.2.2 隐马尔科夫模型（结构）

隐马尔可夫模型(HMM)组成：



五元组 $\lambda = (S, O, \pi, A, B)$

或简写为 $\lambda = (\pi, A, B)$

要素	含义	实例
S	模型中状态的有限集合	天气
O	每个状态可能的观察值	海藻
A	与时间无关的状态转移概率矩阵	天气转移概率矩阵
B	给定状态下，观察值概率分布	每个天气状态的海藻观测概率
π	初始状态空间的概率分布	初始时选择某天气概率

9.2.2 隐马尔科夫模型（结构）

HMM五元组 说明：

1. **隐藏状态 s** ：一个系统的（真实）状态，可以由一个马尔科夫过程
进行描述（如，天气）
2. **观察状态 o** ：在这个过程中‘可视’的状态（例如，海藻的湿度）
3. **状态转移概率矩阵 $A = a_{ij}$** ：包含了一个隐藏状态到另一个隐藏状态
的概率。其中，

$$\left\{ \begin{array}{l} a_{ij} = p(q_{t+1} = S_j | q_t = S_i), \quad 1 \leq i, j \leq N \\ a_{ij} \geq 0 \\ \sum_{j=1}^N a_{ij} = 1 \end{array} \right.$$

9.2.2 隐马尔科夫模型（结构）

4. 观察概率矩阵 $\mathbf{B}=\mathbf{b}_j(\mathbf{k})$: 从隐藏状态 S_j 观察到某一特定符号 v_k 的概率分布矩阵。其中 ,

$$\left\{ \begin{array}{l} b_j(k) = p(O_t = v_k \mid q_t = S_j), \quad 1 \leq j \leq N, \quad 1 \leq k \leq M \\ b_j(k) \geq 0 \\ \sum_{k=1}^M b_j(k) = 1 \end{array} \right.$$

5. 初始状态的概率分布为 : $\pi = \pi_i$, 其中,

$$\left\{ \begin{array}{l} \pi_i = p(q_1 = S_i), \quad 1 \leq i \leq N \\ \pi_i \geq 0 \\ \sum_{i=1}^N \pi_i = 1 \end{array} \right.$$

9.2.2 隐马尔科夫模型（结构）

HMM的三个假设：

对于一个随机事件，有一观察值序列： $O = O_1, O_2, \dots, O_T$

该事件隐含着一个状态序列： $Q = q_1, q_2, \dots, q_T$ 。

假设1：马尔可夫性假设（状态构成一阶马尔可夫链）

$$P(q_i | q_{i-1} \dots q_1) = P(q_i | q_{i-1})$$

假设2：不动性假设（状态与具体时间无关）

$$P(q_{i+1} | q_i) = P(q_{j+1} | q_j), \text{ 对任意 } i, j \text{ 成立}$$

假设3：输出独立性假设（输出仅与当前状态有关）

$$p(O_1, \dots, O_T | q_1, \dots, q_T) = \prod p(O_t | q_t)$$


9.2.2 隐马尔科夫模型（结构）

HMM的特点：

- HMM的**状态是不确定或不可见**的，只有通过观测序列的随机过程才能表现出来
- 观察到的事件与状态**并不是一一对应**，而是通过一组概率分布相联系
- HMM是一个双重随机过程，两个组成部分：
 - **马尔可夫链**：描述状态的转移，用转移概率描述。
 - **一般随机函数**：描述状态与观察序列间的关系，用观察值概率描述。

9.2.2 隐马尔科夫模型（结构）

隐马尔可夫模型(HMM)：



输入：观察序列

输出：1. 观察序列的概率值 2. 隐状态序列

参数： $P(q_t|q_{t-1})$, $P(O_t|q_t)$
A矩阵 B矩阵

用隐马尔可夫模型可求：

I. 在给定模型中出现观察序列的可能性（**概率值**） **HMM评估问题**


II. 通过观察序列找出最大可能的**隐状态序列** **HMM解码问题**

要素	含义	实例
S	模型中状态的有限集合	天气
O	每个状态可能的观察值	海藻
A	与时间无关的状态转移概率矩阵	天气转移概率矩阵
B	给定状态下，观察值概率分布	每个天气状态的海藻观测概率
π	初始状态空间的概率分布	初始时选择某天气概率

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

HMM评估问题：

对于给定观察序列 $O=O_1, O_2, \dots, O_T$ 以及模型 $\lambda = (A, B, \pi)$
求观察序列的概率 $P(O|\lambda)$



求：观察序列概率 $P(O|\lambda) = ?$

问题：


1. 观察序列概率 $P(O|\lambda)$ 定义
2. 如何计算 $P(O|\lambda)$

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

已知

1. 观察序列概率 $P(O|\lambda)$ 定义

- 对于给定的一个状态序列 $Q = q_1q_2\dots q_T$,



$$P(O, Q | \lambda) = \underbrace{\pi_{q_1} a_{q_1q_2} a_{q_2q_3} \dots a_{q_{T-1}q_T}}_{P(Q | \lambda)} \underbrace{b_{q_1}(O_1) b_{q_2}(O_2) \dots b_{q_T}(O_T)}_{P(O | Q, \lambda)}$$

$S = \{\text{晴天}, \text{阴天}, \text{下雨}\}$

$O = \{\text{湿润}, \text{潮湿}, \text{稍干}, \text{干燥}\}$


		晴天	阴天	下雨
A	晴天	0.50	0.25	0.25
	阴天	0.375	0.25	0.375
	下雨	0.25	0.125	0.625

		干	稍干	潮湿	湿润
B	晴天	0.60	0.20	0.15	0.05
	阴天	0.25	0.25	0.25	0.25
	下雨	0.05	0.10	0.35	0.50

$\pi = (1, 0, 0)$

$$P(O, Q | \lambda) = P(Q | \lambda) P(O | Q, \lambda)$$

- 对于全部状态序列



观察序列概率：


$$P(O | \lambda) = \sum_Q P(O, Q | \lambda) = \sum_Q P(Q | \lambda) P(O | Q, \lambda)$$

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

2. 如何计算 $P(O|\lambda)$

观察序列概率：

$$P(O|\lambda) = \sum_Q P(O, Q|\lambda) = \sum_Q P(Q|\lambda)P(O|Q, \lambda)$$



已知

$S = \{\text{晴天, 阴天, 下雨}\}$

$O = \{\text{湿润, 潮湿, 稍干, 干燥}\}$

		晴天	阴天	下雨
A	晴天	0.50	0.25	0.25
	阴天	0.375	0.25	0.375
	下雨	0.25	0.125	0.625


		干	稍干	潮湿	湿润
B	晴天	0.60	0.20	0.15	0.05
	阴天	0.25	0.25	0.25	0.25
	下雨	0.05	0.10	0.35	0.50

$\pi = (1, 0, 0)$

(1) 穷举法：找到每一个可能的隐藏状态的序列，这里有 $3^3 = 27$ 种，可观察序列的概率就是这27种可能的和。很显然，这种计算的效率非常低，尤其是当模型中的状态非常多或者序列很长的时候。

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

穷举法的问题：



◆ 困难：

如果模型 μ 有 N 个不同的状态，时间长度为 T ，那么有 N^T 个可能的状态序列，搜索路径成指数级组合爆炸。

解决方法：

▲ (2) 前向算法（后向算法）：利用动态规划使用递归来降低计算复杂度

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题



向前算法

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

前向算法基本思想：


使用递归来降低计算复杂度

$$P(O | \lambda) = \sum_Q P(O, Q | \lambda) = \sum_Q P(Q | \lambda) P(O | Q, \lambda)$$



9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

前向算法实现：



定义 前向变量 $\alpha_t(j)$ （部分概率），表示达到某个中间状态的概率

➤ 当 $t=1$ 时，是初始概率， $\Pr(\text{状态 } j \mid t=1) = \pi(\text{状态 } j)$

$$\alpha_1(i) = \pi_i b_i(O_1), \quad t=1$$

➤ 当 $1 \leq t \leq T-1$ 时，

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(O_t), \quad 1 \leq t \leq T-1$$

➤ 最终结果 $p(O \mid \mu) = \sum_{i=1}^N \alpha_T(i)$

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

前向算法 (The forward procedure)

(1) 初始化： $\alpha_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$

(2) 循环计算：

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1$$

(3) 结束，输出：

$$p(O|\mu) = \sum_{i=1}^N \alpha_T(i)$$

前向计算过程见附录

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

算法的时间复杂性：

每计算一个 $\alpha_t(i)$ 必须考虑从 $t-1$ 时的所有 N 个状态转移到状态 S_i 的可能性，时间复杂性为 $O(N)$ ，对应每个时刻 t ，要计算 N 个前向变量： $\alpha_t(1), \alpha_t(2), \dots, \alpha_t(N)$ ，所以，时间复杂性为： $O(N) \times N = O(N^2)$ 。又因 $t = 1, 2, \dots, T$ ，所以前向算法总的复杂性为： **$O(N^2T)$**

穷举算法的时间开销是和 T 指数相关 即 **$O(N^T)$**

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

例1： 已有天气和海藻关系的HMM模型 λ ；求连续3 天海藻湿度的观察结果是（干燥、潮湿、湿润）的概率。

$S = \{\text{晴天}, \text{阴天}, \text{下雨}\}$

$O = \{\text{湿润}, \text{潮湿}, \text{稍干}, \text{干燥}\}$


A

	晴天	阴天	下雨
晴天	0.50	0.25	0.25
阴天	0.375	0.25	0.375
下雨	0.25	0.125	0.625

B

天气	海藻			
	干	稍干	潮湿	湿润
晴天	0.60	0.20	0.15	0.05
阴天	0.25	0.25	0.25	0.25
下雨	0.05	0.10	0.35	0.50

$\pi \quad \pi = (1, 0, 0)$



9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

解：用向前算法

			海藻					
晴天	阴天	下雨						
			干	稍干	潮湿	湿润		
晴天	0.50	0.25	0.25	晴天 阴天 下雨	0.60	0.20	0.15	0.05
阴天	0.375	0.25	0.375		0.25	0.25	0.25	0.25
下雨	0.25	0.125	0.625		0.05	0.10	0.35	0.50

$$\pi = (1, 0, 0)$$

1. 前向算法

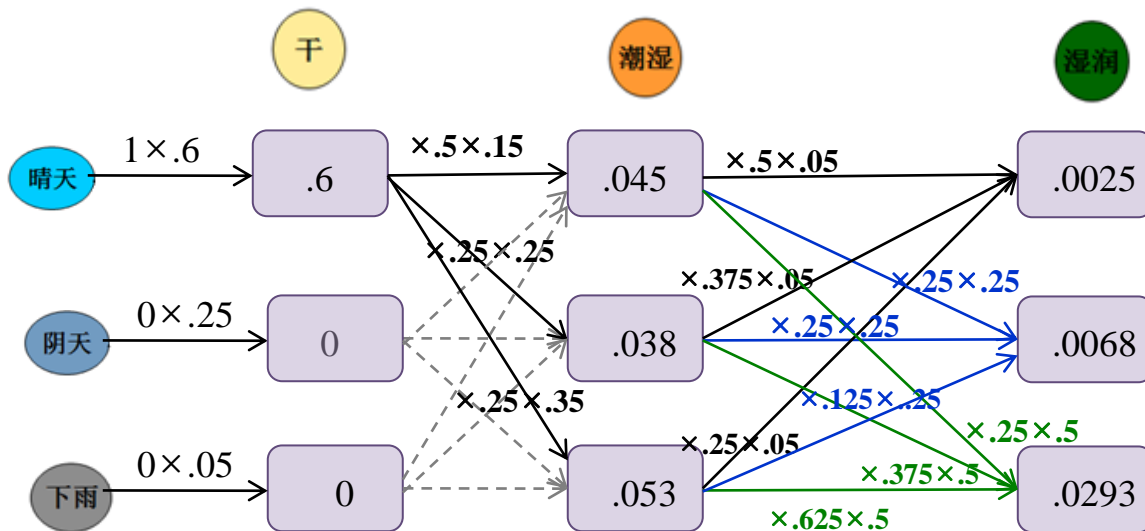
(1) 初始化： $\alpha_1(i) = \pi_i b_i(O_1)$, $1 \leq i \leq N$

(2) 循环计算：

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1$$

(3) 结束，输出：

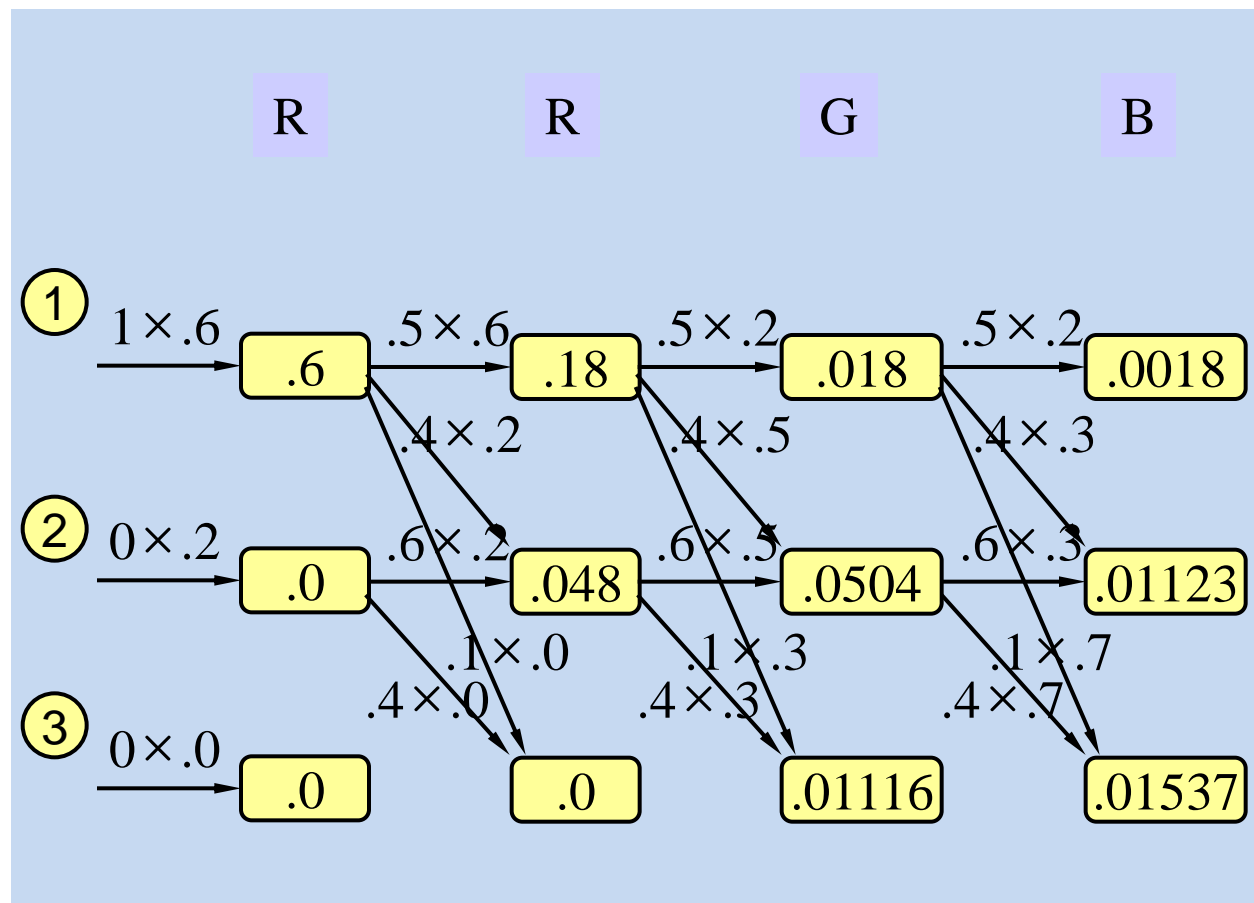

$$p(O|\mu) = \sum_{i=1}^N \alpha_T(i)$$



$$p(O|\mu) = \sum_{i=1}^N \alpha_T(i) = 0.0025 + 0.0068 + 0.0293 = 0.0386$$

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

例 2：




$$p(O|\mu) = \sum_{i=1}^N \alpha_T(i) = .0018 + .01123 + .01537 = .0284$$

9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

向后算法

9.2.2 隐马尔科夫模型（结构）— I. HMM评估问题

后向算法：与前向算法一样，运用动态规划计算**后向量**



归纳顺序： $\beta_T(x), \beta_{T-1}(x), \dots, \beta_1(x)$

➤ 当 $t=T$ 时， $\beta_T(i)=1, 1 \leq i \leq N$


➤ 当 $T-1 \geq t \geq 1$ 时，

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), \quad T-1 \geq t \geq 1, 1 \leq i \leq N$$

➤ 结果：

$$P(O | \mu) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$$

定义**后向变量** $\beta_t(i)$



9.2.2 隐马尔科夫模型（结构）— I . HMM评估问题

后向算法 (The backward procedure)

(1) 初始化 : $\beta_T(i) = 1, 1 \leq i \leq N$

(2) 循环计算 :

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), \quad T-1 \geq t \geq 1, 1 \leq i \leq N$$

(3) 输出结果 :


$$P(O | \mu) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$$

算法的时间复杂性 : $O(N^2T)$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

HMM解码问题：

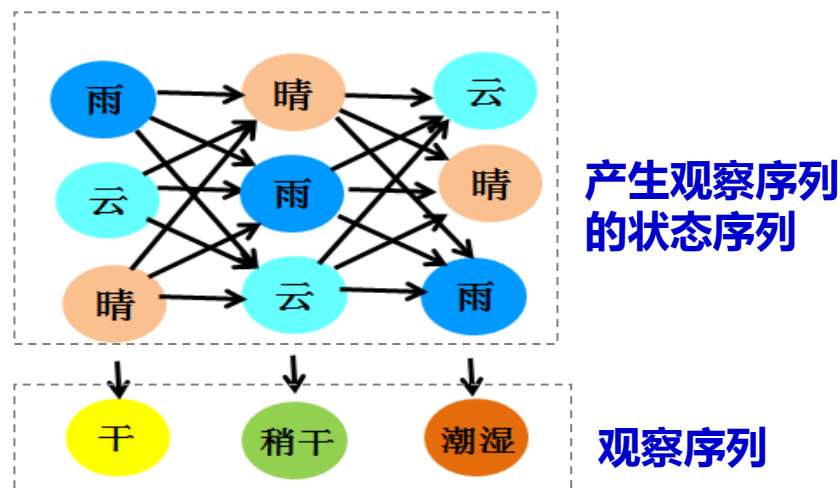

对于给定观察序列 $O = O_1, O_2, \dots, O_T$ ，以及模型 $\lambda = (A, B, \pi)$ 如何选择一个对应的状态序列 $S = S_1, S_2, \dots, S_T$ ，使得 S 能够最为合理的解释观察序列 O



求：状态序列 $S = S_1, S_2, \dots, S_T$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

求：状态序列序列 $S = S_1, S_2, \dots, S_T$



(1) 穷举法：找到每一个可能产生观察序列的状态序列，这里有 $3^3 = 27$ 种，计算每种可能情况下观察序列的概率，概率最大的状态序列就是要找的状态序列。很显然，这种计算的效率非常低，尤其是当模型中的状态非常多或者序列很长的时候。

解决方法：

(2) Viterbi 搜索算法：利用动态规划使用递归来降低计算复杂度

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

Viterbi 搜索算法



Andrew Viterbi


安德鲁·维特比 (Andrew Viterbi)

1967年发明了维特比算法。

维特比算法：利用动态规划方法解决特殊的篱笆网络有向图的最短路径问题。是现代数字通信中使用最频繁的算法；同时也是很多自然语言处理的解码算法。

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

Viterbi 算法基本思想： 使用递归来降低复杂度




1. 如果概率最大路径（或说最短路径）经 i 时刻某个点，一定可以找到 S 到该点的最短路径（可将 i 时刻点的最短路径记录）
2. 从 S 到 E 的路径必定经过 i 时刻的某个点
3. 当从状态 i 进入到 $i+1$ 状态时计算 S 到 $i+1$ 状态时，只考虑 i 状态所有节点最短路径和和它们到 $i+1$ 状态的距离即可。

Viterbi时间复杂度： $O(N^2T)$

穷举法： $O(N^T)$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

Viterbi 算法实现：



(1) 部分最优路径概率

定义一个部分概率 δ ;用 $\delta(i, t)$ 来表示在 t 时刻 , 到状态 i 的所有可能的序列（路径）中概率最大的序列的概率

$$\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$$

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

(2) 向后指针记录最优路径

利用一个后向指针 φ 来记录导致某个状态最大局部概率的前一个状态

$$\phi_t(i) = \arg \max_j (\delta_{t-1}(j) a_{ji})$$

(3) 结果

$$q_t^* = \varphi_{t+1}(q_{t+1}^*), \quad t = T-1, T-2, \dots, 1$$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题


Viterbi 搜索算法

1. 初始化： $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
2. 递归： $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
3. 终结： $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
4. 路径回溯： $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$

算法的时间复杂度： $O(N^2T)$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

例1： 已有天气和海藻关系的HMM模型 λ 和连续3 天海藻湿度的观察结果（干燥、潮湿、湿润），求最可能的天气序列。



A:

	晴天	阴天	下雨
晴天	0.50	0.25	0.25
阴天	0.375	0.25	0.375
下雨	0.25	0.125	0.625

B:

		海藻			
		干	稍干	潮湿	湿润
天气	晴天	0.60	0.20	0.15	0.05
	阴天	0.25	0.25	0.25	0.25
	下雨	0.05	0.10	0.35	0.50

设： $\pi = (1, 0, 0)$

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

解：用Viterbi 搜索算法

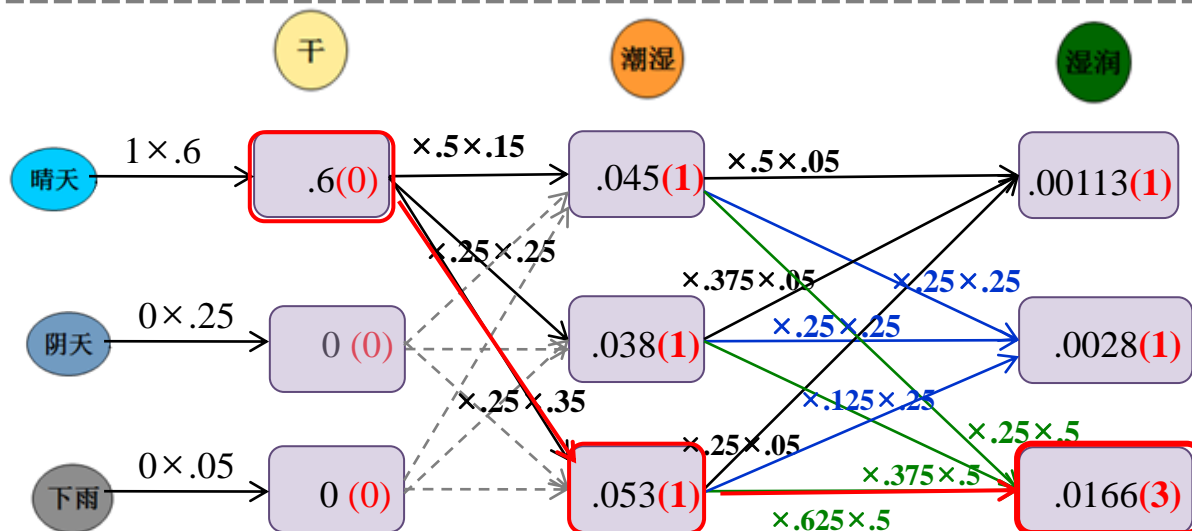
		晴天	阴天	下雨
晴天	$\begin{pmatrix} 0.50 & 0.25 & 0.25 \end{pmatrix}$			
阴天	$\begin{pmatrix} 0.375 & 0.25 & 0.375 \end{pmatrix}$			
下雨	$\begin{pmatrix} 0.25 & 0.125 & 0.625 \end{pmatrix}$			

		海澡			
		干	稍干	潮湿	湿润
晴天	$\begin{pmatrix} 0.60 & 0.20 & 0.15 & 0.05 \end{pmatrix}$				
阴天	$\begin{pmatrix} 0.25 & 0.25 & 0.25 & 0.25 \end{pmatrix}$				
下雨	$\begin{pmatrix} 0.05 & 0.10 & 0.35 & 0.50 \end{pmatrix}$				

$\pi = (1, 0, 0)$

Viterbi 搜索算法

1. 初始化： $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
2. 递归： $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
3. 终结： $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
4. 路径回溯： $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$




(干燥、潮湿、湿润)，最可能的天气序列: (晴、雨、雨)

9.2.2 隐马尔科夫模型（结构）—II. HMM解码问题

例2： HMM模型如下，试根据Viterbi算法计算产生观察符号序列

$O = \{A \ B \ A \ B\}$ 的最优状态序列 Q



解： 初始概率矩阵 $\pi=(1,0,0)$

第一次观察时：

$t=1$

$$\delta_1(1) = \pi_1 * b_1(A) = 1 * 0.7 = 0.7, \quad \psi_1(1) = 0$$

第二次观察时：


$t=2$

$$\delta_2(1) = \delta_1(1) * a_{11} * b_1(B) = 0.7 * 0.4 * 0.3 = 0.084, \quad \psi_2(1) = 1$$

$$\delta_2(2) = \delta_1(1) * a_{12} * b_2(B) = 0.7 * 0.6 * 0.6 = 0.252, \quad \psi_2(2) = 1$$

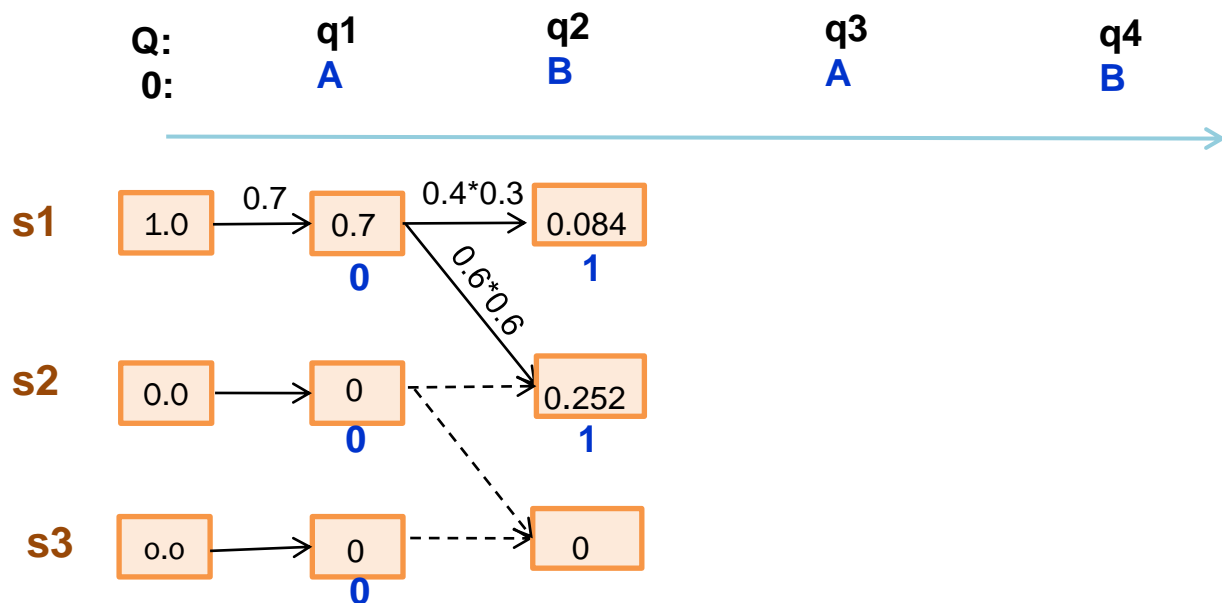
Viterbi 搜索算法

- 初始化： $\delta_1(i) = \pi_i b_i(O_1), \quad \varphi_1(i) = 0, \quad 1 \leq i \leq N$
- 递归： $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$
- 终结： $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯： $q_t^* = \varphi_{t+1}(q_{t+1}^*), \quad t = T-1, T-2, \dots, 1$



A: 0.7 A: 0.4 A: 0.8

B: 0.3 B: 0.6 B: 0.2



解:

第三次观察时:


$t=3$

$$\delta_3(1) = \delta_2(1) * a_{11} * b_1(A) = 0.084 * 0.4 * 0.7 = 0.02352, \psi_3(1) = 1$$

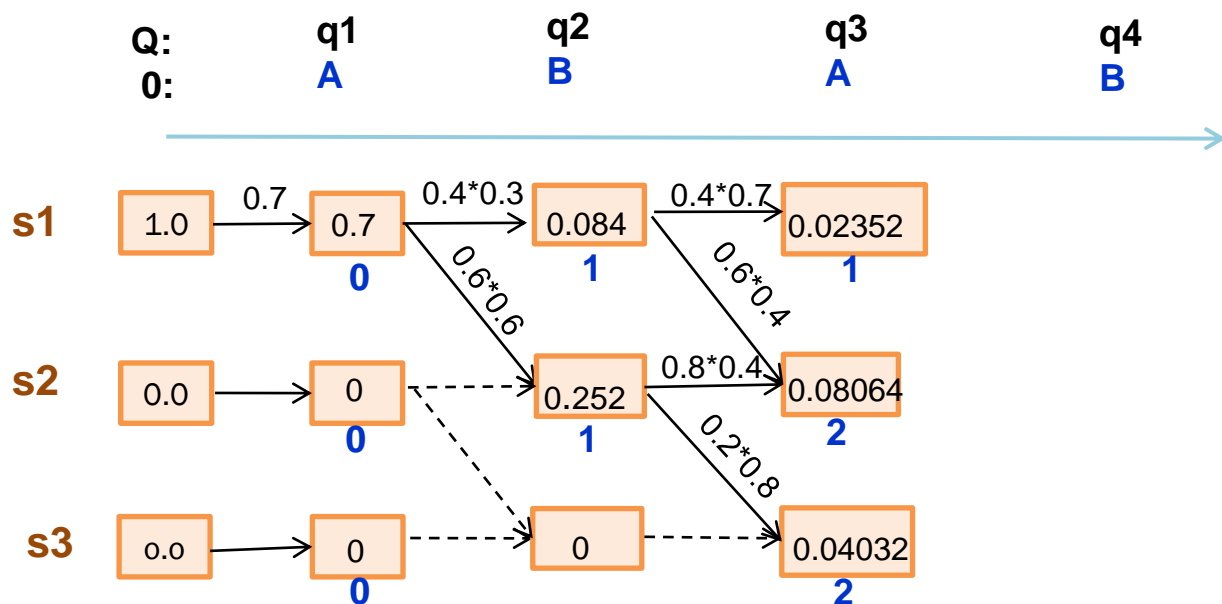
$$\begin{aligned} \delta_3(2) &= \max\{\delta_2(1) * a_{12}, \delta_2(2) * a_{22}\} * b_2(A) \\ &= \max\{0.084 * 0.6, 0.252 * 0.8\} * 0.4, \psi_3(2) = 2 \\ &= 0.08064 \end{aligned}$$

Viterbi 搜索算法

- 初始化: $\delta_1(i) = \pi_i b_i(O_1), \varphi_1(i) = 0, 1 \leq i \leq N$
- 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t), 2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t), 2 \leq t \leq T, 1 \leq j \leq N$
- 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)], q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*), t = T-1, T-2, \dots, 1$



A: 0.7	A: 0.4	A: 0.8
B: 0.3	B: 0.6	B: 0.2



解:

第四次观察时:

t=4


$$\delta_4(1) = \delta_3(1) * a_{11} * b_1(B) = 0.0028224, \quad \psi_4(1) = 1$$

$$\begin{aligned} \delta_4(2) &= \max\{\delta_3(1) * a_{12}, \delta_3(2) * a_{22}\} * b_2(B) \\ &= \max\{0.014112, 0.064512\} * 0.6, \quad \psi_4(2) = 2 \\ &= 0.0387072 \end{aligned}$$

$$\begin{aligned} \delta_4(3) &= \max\{\delta_3(2) * a_{23}, \delta_3(3) * a_{33}\} * b_3(B) \\ &= \max\{0.08064 * 0.2, 0.04032 * 1\} * 0.2, \quad \psi_4(3) = 3 \\ &= 0.008064 \end{aligned}$$

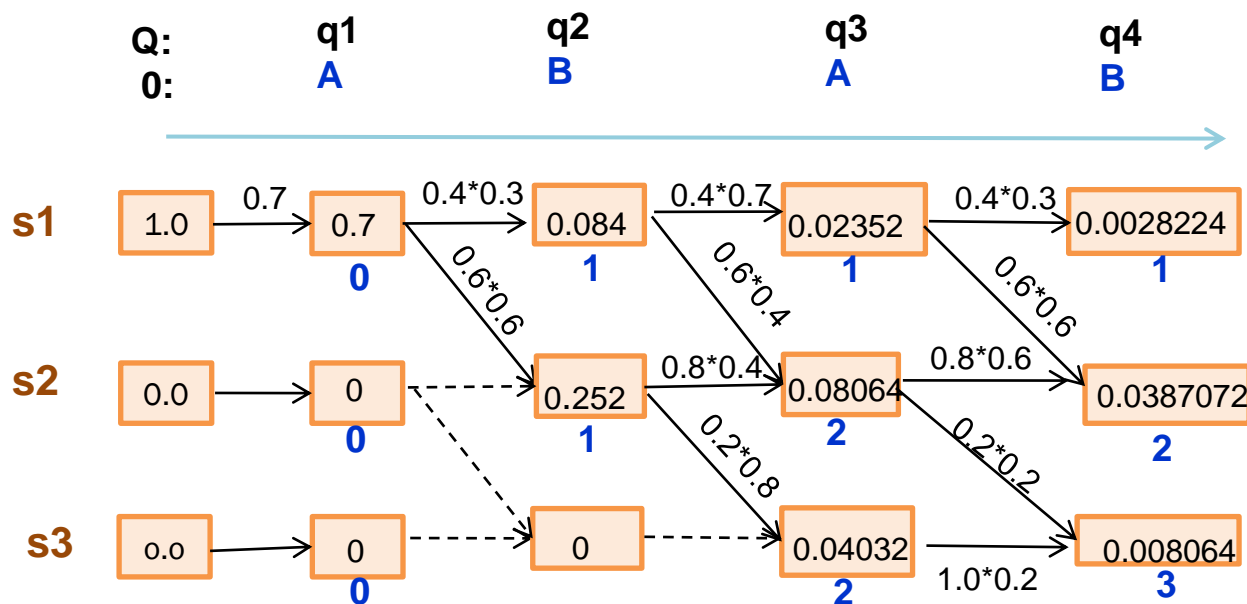
Viterbi 搜索算法

- 初始化: $\delta_1(i) = \pi_i b_i(O_1), \quad \varphi_1(i) = 0, \quad 1 \leq i \leq N$
- 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$
- 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)], \quad q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*), \quad t = T-1, T-2, \dots, 1$



A: 0.7 A: 0.4 A: 0.8

B: 0.3 B: 0.6 B: 0.2



解:

其递推结果为:

$$p^* = \max_{1 \leq i \leq 3} [\delta_4(i)] = \max[0.0028224, 0.0387072, 0.008064] = 0.0387072$$

$$q_4^* = \arg \max_{1 \leq i \leq 3} [\delta_4(i)] = 2$$

$$q_3^* = \psi_4(q_4^*) = \psi_4(2) = 2$$


$$q_2^* = \psi_3(q_3^*) = \psi_3(2) = 2$$

$$q_1^* = \psi_2(q_2^*) = \psi_2(2) = 1$$


最后的结果状态序列为：**S1、S2、S2、S2**

Viterbi 搜索算法

- 初始化: $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
- 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
- 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$



A: 0.7	A: 0.4	A: 0.8
B: 0.3	B: 0.6	B: 0.2



内 容 提 要

9.1 序列标注问题

9.2 隐马尔科夫模型HMM

9.2.1 马尔科夫模型

9.2.2 隐马尔科夫模型（结构）

9.2.3 隐马尔科夫模型学习

9.2.4 隐马模型应用

9.3 条件随机场 CRF

9.4 神经网络 RNN+ CRF

9.2.3 隐马尔科夫模型学习

HMM参数学习

隐马尔科夫模型参数

$$P(S_t | S_{t-1}) = \frac{P(S_{t-1}S_t)}{P(S_{t-1})} \quad P(O_t | S_t) = \frac{P(O'_t S_t)}{P(S_t)}$$

训练思路：

通过观察序列 $O = O_1O_2 \dots O_T$ 作为训练数据，用最大似然估计，使得观察序列 O 的概率 $p(O|\mu)$ 最大。

9.2.3 隐马尔科夫模型学习

情况1： 产生观察序列 O 的状态 $Q = q_1q_2...q_T$ 已知，可以采用**有监督**的学习方法，用**最大似然估计**来计算 μ 的参数：

$$\bar{\pi}_i = \delta(q_1, S_i)$$

$$\bar{a}_{ij} = \frac{Q \text{中从状态 } q_i \text{ 转移到 } q_j \text{ 的次数}}{Q \text{中所有从状态 } q_i \text{ 转移到另一状态(包括 } q_j \text{ 自身)的总数}} = \frac{\sum_{t=1}^{T-1} \delta(q_t, S_i) \times \delta(q_{t+1}, S_j)}{\sum_{t=1}^{T-1} \delta(q_t, S_i)}$$

其中， $\delta(x, y)$ 为克罗奈克(Kronecker)函数，当 $x = y$ 时, $\delta(x, y) = 1$, 否则 $\delta(x, y) = 0$ 。

$$\bar{b}_j(k) = \frac{Q \text{中从状态 } q_j \text{ 输出符号 } v_k \text{ 的次数}}{Q \text{到达 } q_j \text{ 的总次数}} = \frac{\sum_{t=1}^T \delta(q_t, S_j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \delta(q_t, S_j)}$$

其中， v_k 是模型输出符号集中的第 k 个符号。

9.2.3 隐马尔科夫模型学习

情况2：HMM 中的状态序列 Q 是观察不到的，这时，最大似然估计方法不可行。可以采用无监督的EM学习方法。

解决方法：

期望最大化EM 算法。根据**EM 算法**调节模型的参数 π_i a_{ij} , $b_{j(k)}$, 使得观察序列 O 的概率 $P(O|M)$ 最大，主要使用**前向后向算法**（鲍姆-韦尔奇 Baum-Welch ）算法。

（略）

内 容 提 要

9.1 序列标注问题

9.2 隐马尔科夫模型HMM

9.2.1 马尔科夫模型

9.2.2 隐马尔科夫模型（结构）

9.2.3 隐马尔科夫模型学习

9.2.4 隐马模型应用

9.3 条件随机场 CRF

9.4 神经网络 RNN+ CRF

9.2.4 隐马模型应用

HMM模型在自然语言处理中有着广泛的应用

- ★ **分词**：HMM的评估问题：当分词出现多种可能时，求观察序列 $O=O_1O_2...O_T$ 的概率，结果取 概率最大的序列；解码问题：用序列标注直接进行分词
- ★ **词性标注**：相当HMM的解码问题。即求观察序列 $O=O_1O_2...O_T$ 下，概率最大的标注序列 $\text{argmax } P(Q|O, \mu)$
- ★ **其他**：如 短语识别、语音识别

HMM模型相关工具 HTK 地址：<http://htk.eng.cam.ac.uk/>

9.2.4 隐马模型应用

1. 应用中HMM中各部分与自然语言的对应关系：

观察序列 $O = O_1 O_2 \dots O_T$ ：处理的语言单位，一般为 **词**

状态序列 $S = S_1 S_2 \dots S_T$ ：与语言单位对应的句法信息，一般为 **词类**

模型参数：初始状态概率、状态转移概率、发射概率 需要学习获得

9.2.4 隐马模型应用

2. 参数学习（获得）方法：

情况1：有大规模分词和词性标注语料 用最大似然估计方法计算各概率

$$\bar{\pi}_{\text{pos}_i} = \frac{\text{POS}_i \text{出现在句首的次数}}{\text{所有句首的个数}}$$

$$\bar{a}_{ij} = \frac{\text{从词类POS}_i \text{转移到词类POS}_j \text{的次数}}{\text{所有从状态POS}_i \text{转移到另一POS (包括POS}_j \text{) 的总数}}$$

$$\bar{b}_{j(k)} = \frac{\text{从状态POS}_j \text{输出词} w_k \text{的次数}}{\text{状态POS}_j \text{出现的总次数}}$$

注：● \bar{a}_{ij} 中状态数目POS：为语料中词类标记符号的总个数

不同的语料标记个数不同，如 滨州树库汉语33个词类标记；
北大语料106个标记

● $\bar{b}_{j(k)}$ 为所有词类到各单词的概率

如某单词无某一词类，则该词类到此单词的发射概率为 0

9.2.4 隐马模型应用

情况2： 无标注语料：

- ◆ 需要一部有词性标注的词典
 - 获取词类个数(POS状态数)；
 - 获取对应每种词类的词汇数(观察符号数)
- ◆ 利用无监督**EM迭代算法**获取初始 状态概率、
状态转移概率 和 发射概率

9.2.4 隐马模型应用

例： HMM模型在词性标注中的应用

设，有如下从语料库训练得到的词性转移概率矩阵和词语生成概率矩阵

词性转移概率

词性	估计
$PROB(ART \phi)$	0.71
$PROB(N \phi)$	0.29
$PROB(N ART)$	1
$PROB(V N)$	0.43
$PROB(N N)$	0.13
$PROB(P N)$	0.44
$PROB(N V)$	0.35
$PROB(ART V)$	0.65
$PROB(ART P)$	0.74
$PROB(N P)$	0.26

词语生成概率

$PROB(the ART)$	0.54
$PROB(flies N)$	0.025
$PROB(flies V)$	0.076
$PROB(like V)$	0.1
$PROB(like P)$	0.068
$PROB(like N)$	0.012
$PROB(a ART)$	0.360
$PROB(a N)$	0.001
$PROB(flower N)$	0.063
$PROB(flower V)$	0.05
$PROB(birds N)$	0.076


试对 “ flies like a flower ” 进行词性标注

9.2.4 隐马模型应用

解： **问题求解目标**：对每个词标出其词性

该问题属于序列标注问题，可用HMM模型进行标注

HMM



观察集（词集）：flies, like, a, flower

状态集（词性集）：N, V, P, ART

- 共有 256 种可能标注结果
- 可用 Viterbi 搜索算法 解码

词性转移概率

词性	估计
$PROB(ART \emptyset)$	0.71
$PROB(N \emptyset)$	0.29
$PROB(N ART)$	1
$PROB(V N)$	0.43
$PROB(N N)$	0.13
$PROB(P N)$	0.44
$PROB(N V)$	0.35
$PROB(ART V)$	0.65
$PROB(ART P)$	0.74
$PROB(N P)$	0.26

词语生成概率

$PROB(the ART)$	0.54
$PROB(flies N)$	0.025
$PROB(flies V)$	0.076
$PROB(like V)$	0.1
$PROB(like P)$	0.068
$PROB(like N)$	0.012
$PROB(a ART)$	0.360
$PROB(a N)$	0.001
$PROB(flower N)$	0.063
$PROB(flower V)$	0.05
$PROB(birds N)$	0.076

Viterbi 搜索算法

- 初始化: $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
- 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
- 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$

观察序列 (词)

flies

like

a

flower



V



N



P



ART

状态
(词性)

词性转移概率

词性	估计
$PROB(ART \emptyset)$	0.71
$PROB(N \emptyset)$	0.29
$PROB(N ART)$	1
$PROB(V N)$	0.43
$PROB(N N)$	0.13
$PROB(P N)$	0.44
$PROB(N V)$	0.35
$PROB(ART V)$	0.65
$PROB(ART P)$	0.74
$PROB(N P)$	0.26

词语生成概率

$PROB(the ART)$	0.54
$PROB(flies N)$	0.025
$PROB(flies V)$	0.076
$PROB(like V)$	0.1
$PROB(like P)$	0.068
$PROB(like N)$	0.012
$PROB(a ART)$	0.360
$PROB(a N)$	0.001
$PROB(flower N)$	0.063
$PROB(flower V)$	0.05
$PROB(birds N)$	0.076

Viterbi 搜索算法

1. 初始化: $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
2. 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
3. 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
4. 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$

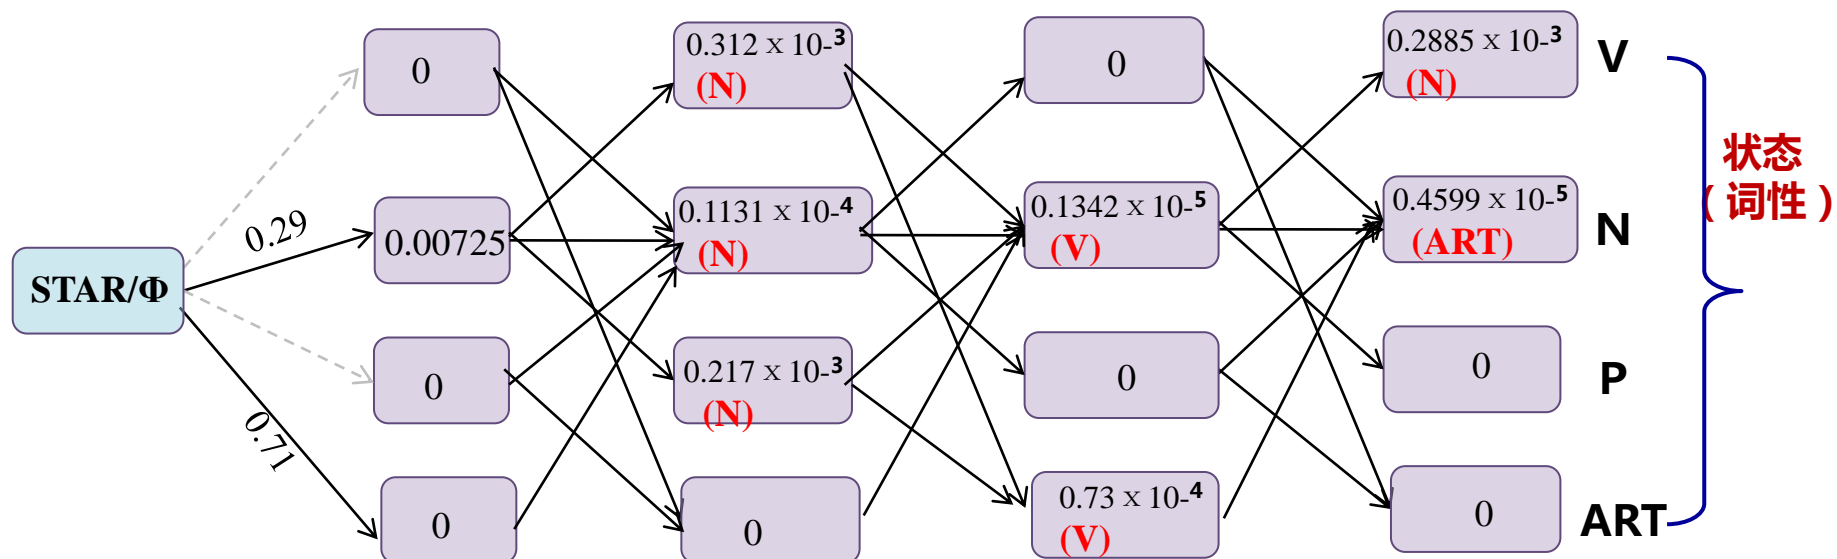
观察序列 (词)

flies

like

a

flower



词性转移概率

词性	估计
$PROB(ART \emptyset)$	0.71
$PROB(N \emptyset)$	0.29
$PROB(N ART)$	1
$PROB(V N)$	0.43
$PROB(N N)$	0.13
$PROB(P N)$	0.44
$PROB(N V)$	0.35
$PROB(ART V)$	0.65
$PROB(ART P)$	0.74
$PROB(N P)$	0.26

词语生成概率

$PROB(the ART)$	0.54
$PROB(flies N)$	0.025
$PROB(flies V)$	0.076
$PROB(like V)$	0.1
$PROB(like P)$	0.068
$PROB(like N)$	0.012
$PROB(a ART)$	0.360
$PROB(a N)$	0.001
$PROB(flower N)$	0.063
$PROB(flower V)$	0.05
$PROB(birds N)$	0.076

Viterbi 搜索算法

- 初始化: $\delta_1(i) = \pi_i b_i(O_1)$, $\varphi_1(i) = 0$, $1 \leq i \leq N$
- 递归: $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
- 终结: $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
- 路径回溯: $q_t^* = \varphi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$

观察序列 (词)

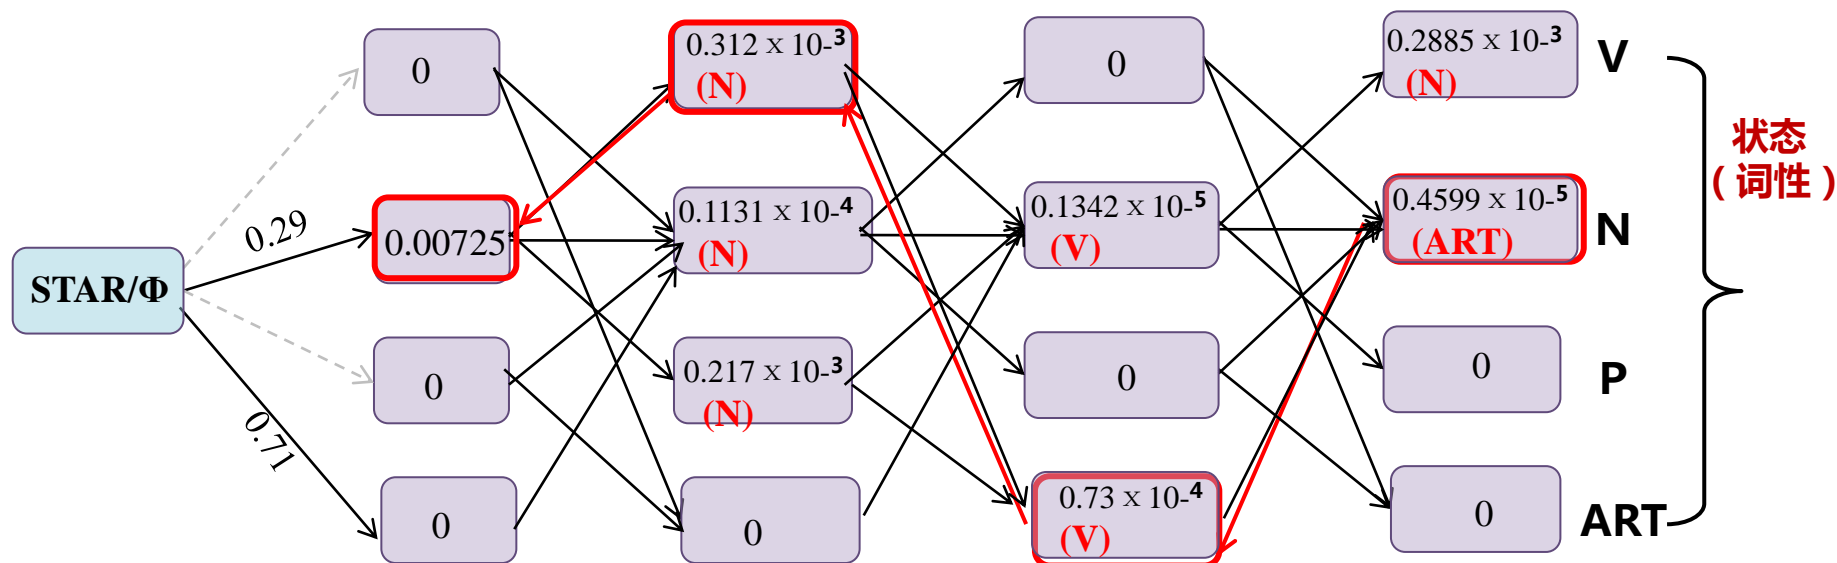
flies /N

like /V

a /ART

flower /N

结果



9.2.4 隐马模型应用


HMM 等生产式模型存在的问题

1. 由于生成模型定义的是联合概率，必须列举所有观察序列的可能值，这对多数领域来说是比较困难的。

在自然语言处理中，常知道各种各样但又不完全确定的信息，需要一个统一的模型将这些信息综合起来。

2. 输出独立性假设要求序列数据严格相互独立才能保证推导的正确性，导致其不能考虑上下文特征

在自然语言处理中，常常需要考虑上下文关系。



解决方案 **➡** 条件随机场 (CRF)

参考文献：

<http://wenku.baidu.com/view/3cf29130f111f18583d05a57.html>

<http://wenku.baidu.com/view/9121f528bd64783e09122b80.html>

<http://wenku.baidu.com/view/bbd57f82fc4ffe473268ab59.html?from=search>

邹博，熵导论与最大熵模型，机器学习班

李航，统计学习方法 清华大学出版社

宗成庆，统计自然语言处理（第2版）

在此表示感谢！


谢谢各位！




附录：

前向计算过程演示

前向算法过程演示



前向算法过程演示




前向算法过程演示




前向算法过程演示



前向算法过程演示



前向算法过程演示



前向算法过程演示

$$\alpha_{t+1}(j) = [\sum_{i=1}^N \alpha_t(i) a_{ij}] b_j(O_{t+1})$$

 $i=N$

i=N-1

i=5

i=4

i=3

i=2

i=1

t=2

t=3

t=4

t=5

t=6


t=7

t=T-1


t=T

2. 递归


前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示




前向算法过程演示



前向算法过程演示



前向算法过程演示



前向算法过程演示

前向算法过程演示

前向算法过程演示

3. 计算 $P(\mathbf{O}|\lambda)$

$i=N$

$i=N-1$

$i=5$

$i=4$

$i=3$

$i=2$

$i=1$

$t=1$

$t=2$

$t=3$

$t=4$

$t=5$

$t=6$

$t=7$

$t=T-1$

$t=T$

前向算法过程演示

